

REDES NEURAIS CONVOLUCIONAIS NA CLASSIFICAÇÃO DE TUMORES

Maria Yessenia Alvarez Gil

Centro de Ciências Exatas e da Natureza
Programa de Pos-graduação em Estatística–CCEN

TÓPICOS ESPECIAIS EM ESTATÍSTICA COMPUTACIONAL

01 de Dezembro de 2024



UNIVERSIDADE
FEDERAL
DE PERNAMBUCO


- Introdução
- Objetivo do trabalho
- Conjunto de dados
- Fundamentos teóricos e metodológicos
- Aplicação
 - Arquitetura do modelo
 - Avaliação e resultados
- Conclusões

O câncer, especialmente o tumor cerebral, é uma das formas mais letais de câncer. Sua identificação precoce é crucial para tratamento adequado. A ressonância magnética (RM) é eficaz para detectar tumores, mas a análise manual é desafiadora e sujeita a erros humanos, devido à complexidade das imagens.



Figura: Tomada de:
<https://enfamilia.aeped.es/temas-salud/tumores-cerebrales>

Objetivo do trabalho



Este trabalho explora o uso de redes neurais convolucionais (CNNs) para a classificação automatizada de tumores cerebrais em imagens de RM. Utilizamos o conjunto de dados público Brain Tumor Classification (MRI), aplicando diferentes pré-processamentos para comparar o desempenho do modelo.


Conjunto de dados

Dataset: Brain Tumor Classification (MRI) (Bhuvaji et al., 2020, Kaggle).

Imagens: 3264 imagens, classificadas em 4 categorias:

- Tumor Glioma
- Tumor Meningioma
- Tumor Pituitary
- Não Tumor

Exemplo de cada classe:




Conjunto de dados (cont.)

Após ajuste:

- Remoção de 181 duplicatas.

Distribuição por classe:



Características das imagens:


- Três canais (RGB).
- Diferentes tamanhos, predominando:
 - (512, 512, 3): 2302 imagens.
 - (236, 236, 3): 52 imagens.
 - (225, 225, 3): 37 imagens.

Pré-processamento dos dados

Etapa essencial para garantir consistência nos dados de entrada e realçar características relevantes.

- **Recorte das imagens:** Remoção de bordas desnecessárias para reduzir ruídos.
- **Redimensionamento:** Ajuste para tamanho fixo, compatível com as CNNs.
- **Normalização:** Escala de pixels para $[0, 1]$, dividindo-os por 255 (valor máximo do RGB), acelerando o treinamento.

Example:



Redes neurais convolucionais (CNNs)

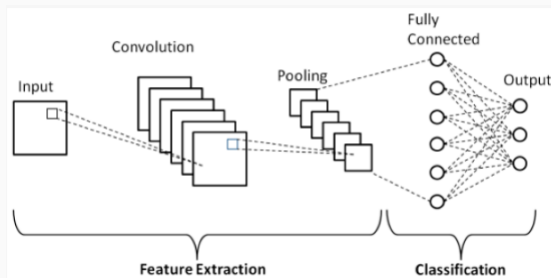


Figura: Tomada de:

<https://www.mdpi.com/2076-3417/9/21/4500>

Estrutura:

- **Camadas convolucionais:** Extração de padrões.
- **Camadas de pooling:** Redução da dimensionalidade.
- **Função ReLU:** Não linearidade e eficiência.
- **Camadas totalmente conectadas:** Integração de características.
- **Camada de saída:** Predição com softmax.

Ferramentas: TensorFlow e Keras para implementação e treinamento.

Estratégias para melhorar o desempenho

- **Dropout:** Redução de sobreajuste desativando neurônios aleatórios (Srivastava et al., 2014).
- **Aumento de dados:** Geração de novas instâncias com transformações como:
 - Rotação, translação e inversão (Shorten & Khoshgoftaar, 2019).





Figura: Tomada de: Circuits Systems and Signal Processing

Total de dados inicial: **3083 imagens** (após remoção de duplicatas).

Pré-Processamento: Imagens ajustadas para **225x225 pixels**, convertidas para **escala de cinza** e **normalização**.

Conjuntos de Dados Criados:

- **Conjunto 1:** Pré-processamento básico descrito acima.
- **Conjunto 2:** Remoção de bordas irrelevantes.
- **Conjunto 3:** Baseado no Conjunto 2, com **150 imagens adicionais** geradas por rotações e transformações leves.



Divisão dos dados:

- 80% Treinamento (30% para validação).
- 20% Teste.

Descrição da arquitetura da rede:

- **Entrada:** Imagem de dimensão (225, 225, 1).
- **Camadas convolucionais:**
 - **Camada 1:** 32 filtros (3, 3), ativação ReLU, seguida de MaxPooling (2, 2) e Dropout (0,2).
 - **Camada 2:** 64 filtros (3, 3), ativação ReLU, seguida de MaxPooling (2, 2) e Dropout.
 - **Camada 3:** 128 filtros (3, 3), ativação ReLU, seguida de MaxPooling (2, 2) e Dropout.
 - **Camada 4:** 512 filtros (3, 3), ativação ReLU, seguida de MaxPooling (2, 2) e Dropout.
- **Camada flatten:** Transforma a saída convolucional em um vetor unidimensional.
- **Camada densa oculta:** 512 neurônios com ativação ReLU.
- **Camada de saída:** 4 neurônios com ativação softmax para classificação multiclasse.

Treinamento: Os modelos foram treinados por 10 épocas devido a limitações de recursos computacionais.

Resultados de desempenho:

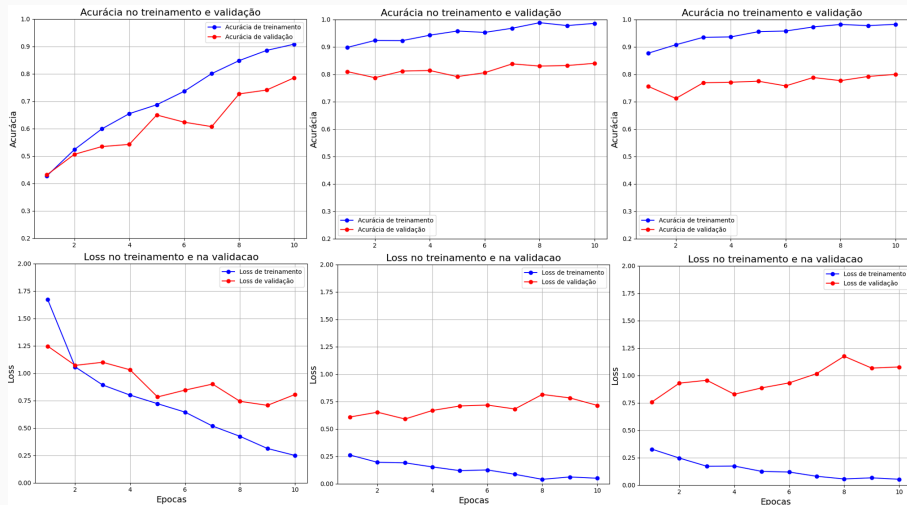
Modelo	Acurácia no Teste	Loss no Teste
Modelo 1	0,81	0,69
Modelo 2	0,88	0,49
Modelo 3	0,86	0,59

Tabela: Desempenho dos modelos nos conjuntos de teste.

Análise: O Modelo 2 apresentou o melhor desempenho.


Avaliação e resultados - Desempenho dos modelos

Curvas de acurácia (superior) e loss (inferior) ao longo do treinamento (linha azul) e validação (linha vermelha) dos três modelos. A primeira coluna corresponde ao Modelo 1, a segunda ao Modelo 2, e a terceira ao Modelo 3.



Avaliação e resultados - Desempenho dos modelos

Matrizes de confusão dos três modelos avaliados.



Redes Neurais Convolucionais:







- Eficácia comprovada na classificação de imagens médicas.
- **Destaque:** Modelo 2 alcançou **88% de acurácia** e menor perda (**0,49**).
- Potencial para lidar com problemas complexos na área médica.

Lições Aprendidas:

- Aumento de dados nem sempre melhora o desempenho; é necessário gerar dados sintéticos de **alta qualidade**.
- A remoção de bordas irrelevantes mostrou-se essencial para otimizar os resultados.
- O pré-processamento adequado é crítico para o sucesso dos modelos.

Estudos Futuros:

- Ajustes arquiteturais para melhorar precisão.
- Uso de mais recursos computacionais para explorar modelos mais complexos.

-  Ayadi, W., Elhamzi, W., Charfi, I., and Atri, M. (2021). Deep CNN for brain tumor classification. *Neural processing letters*, 53:671–700.
-  Bengio, Y., Goodfellow, I., and Courville, A. (2017). *Deep learning*, volume 1. MIT press Cambridge, MA, USA.
-  Bhuvaji, S., Kadam, A., Bhumkar, P., Dedge, S., and Kanchan, S. (2020). Brain tumor classification (MRI). URL: <https://www.kaggle.com/dsv/1183165>.
-  Khan, H. A., Jue, W., Mushtaq, M., and Mushtaq, M. U. (2021). Brain tumor classification in MRI image using convolutional neural network. *Mathematical Biosciences and Engineering*.
-  Kingma, D. P. (2014). Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.
-  Shorten, C. and Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning. *Journal of big data*, 6(1):1–48.